

Proposition de Toy Project : Prédiction d'Approbation des Claims Médicaux avec IA

Mamady Konaté
Stagiaire chez Teliya Santé

21 octobre 2025

1 Introduction

En attendant le lancement du projet principal d'intégration d'un module IA pour la validation automatique des prestations médicales, je propose ce toy project comme exercice pratique. Il utilise un dataset synthétique de claims d'assurance santé issu de Kaggle ("Enhanced Health Insurance Claims Dataset") pour simuler la prédiction de validation/rejet des prestations. Cela me permettra de m'entraîner sur des étapes similaires à la feuille de route du projet principal, tout en respectant la confidentialité des données (dataset anonymisé et synthétique).

Objectifs généraux : - Appliquer des techniques de ML pour prédire l'approbation/rejet d'un claim médical. - Explorer data cleaning, modélisation et évaluation. - Préparer des compétences pour le projet Teliya (ex. traitement NLP sur codes médicaux, intégration API simple).

2 Description du Dataset

Le dataset contient environ 4500 lignes de claims synthétiques, avec des colonnes pertinentes pour simuler des prestations médicales. Il est structuré en CSV et inclut une variable cible binaire (ApprovalStatus : Approved/Rejected), ainsi qu'une raison de rejet optionnelle (DenialReason).

Ce dataset colle aux colonnes du projet principal (ex. age_assure → PatientAge, pathologie → DiagnosisCode, decision_medecin → ApprovalStatus).

3 Étape 1 – Planification et Cadrage

Objectif : Définir le périmètre du toy project.

- Identifier les features clés et la cible (ApprovalStatus). - Contraintes : Utiliser uniquement des données synthétiques ; viser une précision > 85%. - Calendrier : 1-2 jours pour implémentation initiale. - Outils : Python (Pandas, Scikit-learn, XGBoost).

Livrable : Notebook Jupyter avec plan et code initial.

Nom de la colonne	Description
ClaimID	Identifiant unique du claim
PatientAge	Âge du patient
PatientGender	Sexe du patient (M/F)
DiagnosisCode	Code de diagnostic (pathologie)
ProcedureCode	Code de procédure (acte médical)
ProviderType	Type/spécialité du prestataire
DateOfService	Date du service médical
ClaimSubmissionDate	Date de soumission du claim
ApprovalStatus	Statut d'approbation (Approved/Rejected)
DenialReason	Raison du rejet (optionnelle)
ClaimAmount	Montant du claim (numérique)

TABLE 1 – Structure principale du dataset Kaggle

4 Étape 2 – Collecte et Préparation des Données

Objectif : Nettoyer et structurer le dataset.

- Charger le CSV et explorer (vérifier nulls, doublons). - Feature engineering : Calculer un délai (ClaimSubmissionDate - DateOfService), dériver un nombre d'actes récents via groupby. - Anonymisation : Déjà synthétique, pas nécessaire. - Normaliser libellés et corriger incohérences.

Livvable : Dataset nettoyé en CSV ou DataFrame prêt.

5 Étape 3 – Labellisation

Objectif : Préparer la variable cible.

Le dataset est déjà labellisé (ApprovalStatus). Pour simuler une campagne : - Mapper 'Approved' → 1, 'Rejected' → 0. - Analyser l'équilibre des classes (gérer imbalance si besoin).

Livvable : Dataset avec cible binaire.

6 Étape 4 – Préparation Technique

Objectif : Rendre les données exploitables pour ML.

- Encodage : One-hot pour catégories (Gender, ProviderType), TF-IDF ou LabelEncode pour codes textuels (DiagnosisCode, ProcedureCode). - Normalisation : Scaler numériques (Age, délai, Amount). - Split : 80% train, 20% test.

Livvable : Ensembles train/test prêts.

7 Étape 5 – Entraînement du Modèle

Objectif : Construire un modèle prédictif.

- Tester modèles : Logistic Regression (baseline), Random Forest, XGBoost. - Pour textes : Ajouter embeddings NLP si besoin (ex. TF-IDF sur codes). - Évaluer : Précision, recall, F1-score (focus recall sur 'Rejected' pour sécurité). - Sauvegarder le meilleur (.pkl).

Livrable : Modèle entraîné avec metrics.

8 Étape 6 – Test et Validation

Objectif : Vérifier la performance.

- Tester sur set test. - Analyser écarts (confusion matrix). - Ajuster hyperparamètres (GridSearch).

Livrable : Rapport de metrics (ex. F1-score > 0.85).

9 Étape 7 – Intégration Simple

Objectif : Simuler une intégration basique.

- Créer une API mock avec Flask (endpoint /predict). - Input : Features d'un claim ; Output : Prédiction + probabilité.

Livrable : Script API fonctionnel.

10 Étape 8 – Phase Pilote (Simulée)

Objectif : Tester sur subset.

- Simuler retours "médicaux" sur 100 claims. - Ajuster basé sur observations.

Livrable : Notes d'amélioration.

11 Étape 9 – Suivi et Amélioration

Objectif : Planifier l'évolution.

- Ajouter monitoring basique (metrics dashboard via Matplotlib). - Idée : Réentraîner avec augmentations data si besoin.

Livrable : Code pour réentraînement.

12 Résultats Attendus

- Modèle performant pour prédire approbation/rejet. - Préparation pour le projet principal (ex. gestion de données médicales, ML supervisé). - Gain en compétences : Data prep, NLP basique, déploiement léger.

13 Conclusion

Ce toy project est une opportunité idéale pour pratiquer en autonomie tout en alignant sur le projet Teliya. Il démontrera ma capacité à implémenter un flux ML end-to-end. Je suis ouvert à des ajustements basés sur vos retours pour l'approbation.